

# Kapazitätsplanung („Prozessdesign“)

# Kapazitätsplanung bei Werkstattproduktion

# Warteschlangensysteme

Werkstücke („Items“) bzw. Kunden- oder Produktionsaufträge („Jobs“) — bei Dienstleistungsproduktion sind das i. d. R. die Kunden/Abnehmer selbst — warten auf Bearbeitung bzw. auf Service.

Bei perfekter Planung („Scheduling“) kann das Kapazitätsangebot exakt auf die -nachfrage abgestimmt werden. Dies gelingt aber auch nur unter besonders günstigen Bedingungen.

Hinzukommende stochastische Einflüsse führen unvermeidlich zu Warteschlangen.

- ▶ Die Kunden haben gewisse Servicewünsche, bzw. es wird eine bestimmte Erzeugnisvariante verlangt.
- ▶ Die Erfüllung der Servicewünsche verlangt eine gewisse Bedienzeit (Servicezeit, Bearbeitungszeit).
- ▶ Die Kundenaufträge kommen in gewissen Zeitabständen an, bzw. es herrscht asynchroner Materialfluss vor.

**Zufällige Schwankungen ( $\Rightarrow$  Stochastizität) !**

## Aufbau von Warteschlangen


- ▶ Die Kunden haben ausgefallene, spezielle Servicewünsche.
- ▶ Die Erfüllung der Servicewünsche dauert außergewöhnlich lange.
- ▶ Es kommen gerade mehr Kunden an, als bedient werden können.


## Abbau von Warteschlangen

- ▶ Die Kunden haben Standard-Servicewünsche.
- ▶ Die Erfüllung der Servicewünsche geht außergewöhnlich schnell.
- ▶ Es kommen gerade weniger Kunden an, als bedient werden können.

Das **Zusammenwirken dieser stochastischen Effekte** ist nicht exakt vorhersagbar !

Eine **zeitliche Koordination** von Servicewünschen und entsprechendem Kapazitätsangebot der Serviceeinrichtung ist nicht möglich !









## Little's Gesetz


Bestand  $L$  = Materialflussgeschwindigkeit  $\lambda$  · Durchlaufzeit  $W$




Doppelter Durchsatz bei gleicher Durchlaufzeit (→ doppelter Bestand):



Gleicher Durchsatz bei erhöhter Durchlaufzeit (→ gesteigener Bestand):





**Auslastung (Workload Rate)** (bei nur einem Server)

$$\rho = E\{T_S\} \cdot \frac{1}{E\{T_A\}} = \frac{\lambda}{\mu}$$

**Bedienrate (Service Rate)**

$$\mu = \frac{1}{E\{T_S\}}$$

**Ankunftsrate (Arrival Rate)**

$$\lambda = \frac{1}{E\{T_A\}}$$

## [Spezialfall:]

- ▶ exponentialverteilte Zwischenankunftszeiten (Poisson-Ankunftsprozess)
  - ▷ Anzahl  $X$  ankommender Werkstücke ist poissonverteilt mit Rate  $\lambda$

$$P[X = 1] = P[N(t + \Delta t) - N(t) = 1] \approx \lambda \Delta t$$

- ▶ exponentialverteilte Bearbeitungszeiten
  - ▷ Anzahl  $Y$  fertiger Werkstücke (wenn  $n$  Server arbeiten) ist poissonverteilt mit Rate  $n \cdot \mu$

- ▶ 1 Server


$$P[Y = 1] = P[N(t + \Delta t) - N(t) = -1] \approx \mu \Delta t$$

## ⇒ M/M/1-Warteschlangensystem

- ▶ unbeschränkter Warteraum, unbeschränkte Kundenquelle, FCFS-Warteschlangendisziplin (FCFS = first come first served)

# M/M/1-Warteschlangensystem

## Bestandsentwicklung



## Zustandswahrscheinlichkeiten

$$\begin{aligned} P_n(t + \Delta t) = & P_n(t) \cdot (1 - \lambda \Delta t) \cdot (1 - \mu \Delta t) \\ & + P_{n+1}(t) \cdot (1 - \lambda \Delta t) \cdot (\mu \Delta t) \\ & + P_{n-1}(t) \cdot (\lambda \Delta t) \cdot (1 - \mu \Delta t) \\ & + P_n(t) \cdot (\lambda \Delta t) \cdot (\mu \Delta t) \end{aligned}$$

## Auslastung

$$\rho = \frac{\lambda}{\mu} = \lambda \cdot E\{T_S\}$$

## Zustandswahrscheinlichkeiten

$$P_n = P[N = n] = P_{n-1} \cdot \rho = P_0 \cdot \rho^n \quad (n = 1, 2, 3, \dots)$$

$$P_0 = P[N = 0] = 1 - \rho$$

## erwarteter Bestand im System

$$L = E\{N\} = \frac{\rho}{1 - \rho}$$

$$\text{Little's Gesetz: } L = \lambda \cdot W$$

## erwartete Durchlaufzeit

$$W = E\{T\} = \frac{L}{\lambda} = \frac{1}{\mu \cdot (1 - \rho)}$$

## Auslastung

$$\rho = \frac{\lambda}{\mu} = \lambda \cdot E\{T_S\}$$

## Zustandswahrscheinlichkeiten

$$P_n = P[N = n] = P_{n-1} \cdot \rho = P_0 \cdot \rho^n \quad (n = 1, 2, 3, \dots)$$

$$P_0 = P[N = 0] = 1 - \rho$$

## erwartete Warteschlangenlänge


$$L_Q = E\{N_Q\} = L - E\{N_S\} = \frac{\rho^2}{1 - \rho}$$

**Little's Gesetz:**  $L_Q = \lambda \cdot W_Q$

## erwartete Wartezeit

$$W_Q = E\{T_Q\} = \frac{L_Q}{\lambda} = \frac{\rho}{\mu \cdot (1 - \rho)}$$

einheitlicher Materialfluss






# Kapazitätsplanung bei Fließproduktion

## Beispiel Arbeitselemente

Arbeitselement Nr. $i$	1	2	3	4	5	6	7	8
Elementzeit $t_i$ [Zeiteinheiten]	3	1	2	5	4	4	7	1

## Vorranggraph (Reihenfolgerestriktionen)




(Beispiel aus Günther/Tempelmeier (2016))

## Beispiel Arbeitselemente

Arbeitselement Nr. $i$	1	2	3	4	5	6	7	8
Elementzeit $t_i$ [Zeiteinheiten]	1.2	1.2	1.8	1.6	1.3	2.0	1.4	1.3

## Vorranggraph (Reihenfolgerestriktionen)



(Beispiel aus Günther/Tempelmeier (2016))

Planungsprobleme:

## ► Leistungsabstimmung

### ▷ Arbeitsanalyse hinsichtlich

- \* Arbeitselemente (elementare Arbeitsgänge)
- \* Elementzeit (Arbeitsgangdauer)
- \* Produktmix (Varianten des Grundprodukts)
- \* Vorranggraph (technologisch bedingte Reihenfolgerestriktionen)

### ▷ Entscheidungsproblem

- \* Minimierung der Anzahl benötigter Bearbeitungsstationen
- \* Aufbau der einzelnen Bearbeitungsstationen:  
Zuordnung der Arbeitselemente zu den Stationen („Arbeitsinhalt“)
- \* Restriktionen:
  - vorgegebene Produktionsrate bzw. Taktzeit
  - Unteilbarkeit der Arbeitselemente
  - z. T. technologisch zwingende Bearbeitungsreihenfolge

[Zunächst unterstellen wir deterministische Bedingungen:]

- ▶ keine Maschinenausfälle
- ▶ keine schwankenden Bearbeitungszeiten
- ▶ keine variantenabhängigen Elementzeiten
- ▶ synchroner Materialfluss

= deterministische Elementzeiten

= 100 %ig zuverlässige Transferstraßen

⇒ „Klassische Fließbandabstimmung“

# Das klassische Fließbandabstimmungsproblem (Simple Assembly-Line Balancing Problem)

# Ein Optimierungsmodell zur klassischen Fließbandabstimmung

## **Modell SALBP**

Was muss festgelegt werden — Entscheidungsvariablen:

$y_m \in \{0; 1\}$  ... Wieviel Stationen werden benötigt?

$$y_m = \begin{cases} 1, & \text{wenn die } m\text{te Station benötigt wird} \\ 0 & \text{sonst} \end{cases}$$

$x_{im} \in \{0; 1\}$  ... Welche Arbeitselemente werden an den einzelnen Stationen ausgeführt?

$$x_{im} = \begin{cases} 1, & \text{wenn Arbeitselement } i \text{ der Station } m \\ & \text{zugeordnet wird} \\ 0 & \text{sonst} \end{cases}$$



## **Modell SALBP**

Was ist gegeben — Indexmengen:

$I$  ... Anzahl Arbeitselemente

$M$  ... maximale Anzahl Stationen

$\mathcal{N}_i$  ... Menge der direkten Nachfolger des Arbeitselements  $i$

Was ist gegeben — Daten:

$C$  ... Taktzeit

$t_i$  ... Elementzeit (Arbeitsgangdauer) des Arbeitselements  $i$

## **Modell SALBP**

Minimiere die Anzahl benötigter Stationen:  $Z = \sum_{m=1}^M y_m$   
unter Berücksichtigung von

### **Zuordnungsrestriktionen**

Vollständige und eindeutige Zuordnung der Arbeitselemente  $i = 1, 2, \dots, I$ :

$$\sum_{m=1}^M x_{im} = 1$$

**Taktzeitrestriktionen:** Obergrenze an allen Stationen  $m = 1, 2, \dots, M$ :

$$\sum_{i=1}^I t_i \cdot x_{im} \leq C \cdot y_m$$

**Reihenfolgerestriktionen** in bezug die Arbeitselemente  $i = 1, 2, \dots, I - 1$ :

$$\sum_{m=1}^M m \cdot x_{im} \leq \sum_{m=1}^M m \cdot x_{jm} \quad (\text{jeweils für die Nachfolgearbeitsgänge } j \in \mathcal{N}_i)$$

Äquivalente Zielsetzungen:

- ▶ Minimiere die **Anzahl Stationen**:

$$Z$$

- ▶ Minimiere die **Durchlaufzeit** eines Werkstücks:

$$Z \cdot C$$

- ▶ Minimiere die Summe der **Leerzeiten**:

$$\sum_{m=1}^Z \left( C - \sum_{i=1}^I t_i \cdot x_{im} \right) = Z \cdot C - \sum_{i=1}^I t_i$$

- ▶ Maximiere die **Auslastung** (den Bandwirkungsgrad):

$$1 - \frac{Z \cdot C - \sum_{i=1}^I t_i}{Z \cdot C} = \frac{\sum_{i=1}^I t_i}{Z \cdot C}$$

# Heuristische Lösungsverfahren


Bilde sukzessive die Stationen durch Zuordnung möglichst vieler Arbeitselemente unter Beachtung der

- ▶ Reihenfolgerestriktionen,
- ▶ Taktzeitrestriktion !

Wähle aus mehreren möglichen Arbeitselementen gemäß einem **Prioritätsregelverfahren** z. B. dasjenige mit

- ▶ der größten Anzahl Nachfolger,
- ▶ der längsten Elementzeit,
- ▶ der kürzesten Elementzeit,
- ▶ dem höchsten Positionswert !  
(= Summe der Elementzeit mit den Elementzeiten der Nachfolger)

## Beispiel Klassische Fließbandabstimmung



### vorgegebene Produktionsrate

$X = 42$  Stück pro Schicht, d. h. 42 Stück in  $T = 462$  [Minuten]

### maximale (größtzulässige) Taktzeit

(= Kehrwert der vorgegebenen Produktionsrate)

$$C = \frac{T}{X} = \frac{462 \text{ [Minuten]}}{42 \text{ [Stück]}} = 11 \text{ Minuten pro Stück}$$


### Mindestanzahl (theoretisch minimale Anzahl) an Stationen

$$M_{\min} = \frac{\sum \text{Elementzeiten}}{C} = \frac{53}{11} = 4.8\bar{1} \implies \text{aufgerundet: } M_{\min} = \lceil 4.8\bar{1} \rceil = 5$$

## Beispiel 10 Arbeitselemente, Taktzeit 11 Minuten

Station	Arbeitselemente		Elementzeit [min]	Stationszeit [min]	Restzeit [min]
	einplanbar nach Reihenfolge	ausgewählt Taktzeit			
I	A	A	5	5	6
	B, C, D	B, C, D	3 mehr Nachfolger als C, ansonsten willkürlich	8	3
II	C, D, E	C, D, E	6 D hat die meisten Nachfolger	6	5
	C, E, G	C nur C passt noch	4 C	10	1
III	E, F, G	E, F, G	8 G hat die meisten Nachfolger	8	3
	E, F, I	F nur F passt noch	3 F	11	0
IV	E, I	E, I	8 E mehr Nachfolger als I	8	3
V	H, I	H, I	5 H willkürlich	5	6
	I	I	6 I	11	0
VI	J	J	5 J	5	6

## Beispiel Klassische Fließbandabstimmung



### Bandwirkungsgrad

$$U = 1 - \frac{\sum \text{Leerzeiten}}{\text{Gesamtdurchlaufzeit}} = 1 - \frac{3 + 1 + 0 + 3 + 0 + 6}{6 \cdot 11} = 80.\overline{30} \%$$



Stochastisch schwankende Bearbeitungszeiten führen zu zufälligen Wartezeiten vor den Stationen.

**Puffer** sind Warteräume/Lager für Werkstücke zwischen zwei Stationen.

## **Leistungsmindernde Effekte bei beschränkten Puffern:**

- ▶ **Starving:** Eine Station kann nicht mit der nächsten Bearbeitung beginnen, weil der davorliegende Puffer leer ist.
- ▶ **Blocking:** Eine Station kann nicht mit der nächsten Bearbeitung beginnen, weil der nachfolgende Puffer voll ist und fertige Werkstücke nicht weitertransportiert werden können.

## Effizienzüberlegungen:

- ▶ Das Ausmaß von Blocking und Starving verkleinert sich mit der Puffergröße. ( $\Rightarrow$  höhere Produktionsrate)
- ▶ Pufferbestände verursachen Lagerkosten.
- ▶ Technische Lösungen für Puffereinrichtungen erfordern Investitionsaufwand.

Planungsprobleme:

## ► Leistungsabstimmung


- ▷ Minimierung der Anzahl benötigter Bearbeitungsstationen
- ▷ Aufbau der einzelnen Bearbeitungsstationen:  
Zuordnung der Arbeitselemente zu den Stationen („Arbeitsinhalt“)
- ▷ Restriktionen:
  - \* vorgegebene Produktionsrate bzw. Taktzeit
  - \* Unteilbarkeit der Arbeitselemente
  - \* z. T. technologisch zwingende Bearbeitungsreihenfolge

## ► Pufferallokation

- ▷ Verteilung einer minimalen Anzahl Pufferplätze zwischen die Stationen, so dass die angestrebte Systemleistung (Produktionsrate) erreicht wird

## ► Leistungsanalyse

# Leistungsanalyse bei stochastischen Bearbeitungszeiten



Betrachtung der Stationen als eine Reihe von Warteschlangensystemen:

- ▶  $\mu_m$  ... Bearbeitungsrate der Station  $m$ ,  
 $b_m$  ... mittlere Bearbeitungszeit eines Werkstücks an der Station  $m$   
 $\implies \mu_m = \frac{1}{b_m}$
- ▶  $\lambda_m$  ... Ankunftsrate von Werkstücken an der Station  $m$
- ▶ unbeschränkte Puffer,  
d. h. Outputrate an Station  $m = \min\{\lambda_m, \mu_m\} = \lambda_{m+1}$
- ▶  $\lambda_1 = \lambda$  ... Ankunftsrate von Werkstücken aus dem Lager für Vorprodukte
- ▶ Produktionsrate

$$X = \min\{\lambda, \mu_1, \mu_2, \dots, \mu_M\}$$

## [Spezialfall:]

- ▶ exponentialverteilte Zwischenankunftszeiten (Poisson-Ankunftsprozess)
- ▶ exponentialverteilte Bearbeitungszeiten, d. h. Stationszeiten

**Auslastung** der Station  $m$ :  $(m = 1, 2, \dots, M)$

$$\rho_m = \frac{\lambda_m}{\mu_m} = \lambda_m \cdot b_m$$

**Zustandswahrscheinlichkeiten** für die Station  $m$ :  $(m = 1, 2, \dots, M)$

$$P_{n_m} = (1 - \rho_m) \cdot \rho_m^{n_m} \quad (n_m = 0, 1, 2, \dots)$$

**mittlerer Bestand** an der Station  $m$ :  $(m = 1, 2, \dots, M)$

$$L_m = \frac{\rho_m}{1 - \rho_m}$$

**mittlere Warteschlangenlänge** vor der Station  $m$ :  $(m = 1, 2, \dots, M)$

$$L_m^Q = \frac{\rho_m^2}{1 - \rho_m}$$

## [Spezialfall:]

- ▶ exponentialverteilte Zwischenankunftszeiten (Poisson-Ankunftsprozess)
- ▶ exponentialverteilte Bearbeitungszeiten, d. h. Stationszeiten

**Auslastung** der Station  $m$ :  $(m = 1, 2, \dots, M)$

$$\rho_m = \frac{\lambda_m}{\mu_m} = \lambda_m \cdot b_m$$

**Zustandswahrscheinlichkeiten** für die Station  $m$ :  $(m = 1, 2, \dots, M)$

$$P_{n_m} = (1 - \rho_m) \cdot \rho_m^{n_m} \quad (n_m = 0, 1, 2, \dots)$$

**mittlerer Bestand** an der Station  $m$ :  $(m = 1, 2, \dots, M)$

$$L_m = \frac{\rho_m}{1 - \rho_m}$$

**mittlere Durchlaufzeit** an der Station  $m$ :  $(m = 1, 2, \dots, M)$

$$W_m = \frac{b_m}{1 - \rho_m}$$

## **Beispiel** Leistungsanalyse bei M/M/1-Subsystemen

- ▶ Reihenproduktion mit insgesamt  $M = 5$  Stationen
- ▶ Ankunftsrate vor der ersten Station:  $\lambda = 0.08$  Stück pro Minute
- ▶ mittlere Bearbeitungszeit an allen Stationen:  $b_m = 10$  Minuten

**Ankunftsrate** an Station  $m$ :

$$\lambda_1 = \lambda = 0.08, \lambda_m = \min\{\lambda_{m-1}, \mu_{m-1}\} = 0.08 \quad (m = 2, \dots, 5)$$

**Stationsauslastung**  $U_m = \lambda_m \cdot b_m = 0.08 \cdot 10 = 0.8$

**Wahrscheinlichkeitsverteilung für den Bestand an den Stationen**

$$P_0 = 0.2, P_1 = 0.16, P_2 = 0.128, P_3 = 0.1024, P_4 = 0.0819, \dots, P_{18} = 0.0036, \dots$$

**Bestand**  $L_m = \frac{\rho_m}{1 - \rho_m} = \frac{0.8}{0.2} = 4, L = \sum_{i=1}^5 L_m = 20$

**Durchlaufzeit**  $W_m = \frac{b_m}{1 - \rho_m} = \frac{10}{0.2} = 50, W = \sum_{i=1}^5 W_m = 250$

**Produktionsrate**  $X = \min\{\lambda, \mu_1, \mu_2, \mu_3, \mu_4, \mu_5\} = 0.08$